



## **Visão computacional na saúde: revisão de métodos e desafios educacionais para integração multidisciplinar**

### **Computer vision in healthcare: review of methods and educational challenges for multidisciplinary integration**

### **Visión por computadora en salud: revisión de métodos y desafíos educativos para la integración multidisciplinaria**

#### **Almir Rodrigues Tavares**

Doutorando em Engenharia Biomédica

Instituição: Universidade de Mogi das Cruzes (UMC)

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: almir.rodrigues.tavares@gmail.com

#### **Helio de Araújo Ribeiro**

Mestrando em Engenharia Biomédica

Instituição: Universidade de Mogi das Cruzes (UMC)

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: helioribeiropro@gmail.com

#### **Higor Barreto Campos**

Doutorando em Biotecnologia

Instituição: Universidade de Mogi das Cruzes (UMC)

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: higor\_barretocampos@gmail.com

#### **Cleber Silva de Oliveira**

Mestre em Engenharia Mecânica

Instituição: UNITAU

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: cleber@ifsp.edu.br

#### **Robson Rodrigues da Silva**

Doutor em Engenharia Biomédica

Instituição: Universidade de Mogi das Cruzes (UMC)

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: robson.silva@umc.br



**Marcia Aparecida Silva Bissaco**

Doutora em Física Computacional

Instituição: Universidade de São Paulo (USP)

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: marciab@umc.br

**Silvia Cristina Martini**

Doutora em Engenharia Elétrica

Instituição: Escola de Engenharia de São Carlos da Universidade de São Paulo (EESC, USP)

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: silviac@umc.br

**Fabiano Bezerra Menegidio**

Doutor em Biotecnologia

Instituição: Universidade de Mogi das Cruzes (UMC)

Endereço: Av. Dr. Cândido Xavier de Almeida e Souza, 200, Mogi das Cruzes, São Paulo, Brasil

E-mail: fabianomenegidio@umc.br

**RESUMO**

O artigo apresenta revisão técnico-científica sobre métodos de visão computacional aplicados à saúde, com foco em avanços recentes, aplicações práticas e desafios multidisciplinares. A utilização de algoritmos de aprendizado profundo em redes neurais convolucionais (CNNs), tem promovido transformações significativas, abrangendo diagnóstico precoce, segmentação de estruturas anatômicas e planejamento de intervenções cirúrgicas. As barreiras éticas, regulatórias e técnicas, incluindo a escassez de dados rotulados relacionadas à LGPD e GDPR são pontos críticos entre os campos da saúde e da ciência da computação, dificultando o uso por profissionais clínicos. As discussões de estratégias para superar essas limitações, como o uso de aprendizado auto supervisionado, redes generativas adversariais (GANs) e técnicas de explicabilidade em inteligência artificial (XAI). A interdisciplinaridade dos currículos especializados criam bases para impulsionar a sustentabilidade da visão computacional. O estudo fomenta avanços no diagnóstico automatizado e na formação educacional de profissionais aptos a integrar essas inovações na prática médica.

**Palavras-chave:** ética, aprendizado profundo, IA, interdisciplinar.

**ABSTRACT**

The article presents a technical-scientific review of computer vision methods applied to healthcare, focusing on recent advances, practical applications, and multidisciplinary challenges. The use of deep learning algorithms in convolutional neural networks (CNNs) has driven significant transformations, encompassing



early diagnosis, anatomical structure segmentation, and surgical planning. Ethical, regulatory, and technical barriers, including the shortage of labeled data related to LGPD and GDPR, are critical issues between the fields of healthcare and computer science, hindering adoption by clinical professionals. Strategies to overcome these limitations are discussed, such as the use of self-supervised learning, generative adversarial networks (GANs), and explainability techniques in artificial intelligence (XAI). The interdisciplinarity of specialized curricula creates foundations to boost the sustainability of computer vision. The study fosters advance in automated diagnosis and the educational training of professionals capable of integrating these innovations into medical practice.

**Keywords:** ethics, deep learning, AI, interdisciplinary.

## RESUMEN

El artículo presenta una revisión técnico-científica sobre métodos de visión computacional aplicados a la salud, con enfoque en avances recientes, aplicaciones prácticas y desafíos multidisciplinarios. El uso de algoritmos de aprendizaje profundo en redes neuronales convolucionales (CNNs) tiene impulsado transformaciones significativas, abarcando diagnóstico temprano, segmentación de estructuras anatómicas y planificación de intervenciones quirúrgicas. Las barreras éticas, regulatorias y técnicas, incluida la escasez de datos etiquetados relacionados con LGPD y GDPR, son puntos críticos entre los campos de la salud y la informática, dificultando su adopción por parte de los profesionales clínicos. Se discuten estrategias para superar estas limitaciones, como el uso de aprendizaje autosupervisado, redes generativas adversariales (GANs) y técnicas de explicabilidad en inteligencia artificial (XAI). La interdisciplinaria de los planes de estudio especializados crea bases para impulsar la sostenibilidad de la visión computacional. El estudio fomenta avances en el diagnóstico automatizado y en la formación educativa de profesionales capacitados para integrar estas innovaciones en la práctica médica.

**Palabras clave:** ética, aprendizaje profundo, IA, interdisciplinar.

## 1 INTRODUÇÃO

A visão computacional, uma subárea da inteligência artificial (IA), tem se consolidado como uma tecnologia essencial na área da saúde, transformando processos clínicos e oferecendo novas possibilidades para diagnóstico, monitoramento e intervenções. Combinando processamento de imagens, aprendizado de máquina e análise de dados, a visão computacional permite



interpretar dados visuais, como imagens médicas e vídeos cirúrgicos, de maneira automatizada e altamente precisa (Esteva *et al.*, 2021).

Esses avanços têm sido possibilitados pelo desenvolvimento de redes neurais convolucionais (CNNs), que, ao longo da última década, superaram algoritmos tradicionais em tarefas visuais, alcançando resultados que, em alguns casos, rivalizam ou superam a performance humana (Altameem & Altameem, 2020).

Na área da saúde, a visão computacional tem aplicações amplas, que incluem diagnósticos automatizados, triagem populacional, monitoramento clínico e planejamento de procedimentos médicos. Por exemplo, métodos baseados em aprendizado profundo são utilizados para a detecção precoce de câncer em exames de mamografia e tomografia computadorizada, demonstrando precisão acima de 90% em algumas tarefas específicas (Chen, 2013). Além disso, avanços recentes na segmentação de imagens médicas têm permitido identificar estruturas anatômicas complexas com alta acurácia, auxiliando em procedimentos cirúrgicos e diagnósticos (Schmidt *et al.*, 2023).

Outro campo de grande impacto é o monitoramento de pacientes em ambientes clínicos e hospitalares. Sistemas de visão computacional têm sido utilizados para rastrear movimentos, detectar quedas em idosos e monitorar sinais vitais de maneira não invasiva, promovendo maior segurança e eficiência em cuidados intensivos (Germanese *et al.*, 2023). No contexto cirúrgico, tecnologias baseadas em visão computacional permitem a identificação de instrumentos e fases cirúrgicas em tempo real, otimizando o fluxo das operações e reduzindo riscos associados a erros humanos (Kennedy-Metz *et al.*, 2021).

Apesar das vantagens proporcionadas, a adoção generalizada da visão computacional na saúde enfrenta desafios significativos. O treinamento de modelos robustos e precisos requer grandes volumes de dados médicos rotulados, cuja disponibilidade é frequentemente limitada por preocupações éticas e regulamentares, como as impostas pelo GDPR na União Europeia e pela LGPD no Brasil (Ramesh *et al.*, 2022). Além disso, questões relacionadas à explicabilidade e transparência dos modelos limitam sua aceitação em



ambientes clínicos, onde profissionais de saúde frequentemente carecem do conhecimento técnico necessário para interpretar os resultados algorítmicos (Esteva *et al.*, 2021).

Outro ponto crítico é a lacuna educacional existente entre as áreas da saúde e da ciência da computação. A falta de disciplinas relacionadas à inteligência artificial e à visão computacional em currículos de medicina e engenharia biomédica cria uma barreira para a formação de profissionais preparados para implementar e utilizar essas tecnologias (Chen, 2013).

O presente artigo tem como objetivo revisar criticamente os avanços em visão computacional aplicada à saúde, com foco nos métodos, aplicações e desafios. Além disso, propõe soluções educacionais para facilitar a adoção dessa tecnologia em larga escala. Nos capítulos seguintes, será abordado um panorama dos fundamentos teóricos da visão computacional, seguido por uma análise detalhada de suas aplicações em saúde, desafios éticos e educacionais e, finalmente, uma discussão sobre as perspectivas futuras do campo.

## **2 REFERENCIAL TEÓRICO**

A visão computacional é um campo interdisciplinar que une conceitos de inteligência artificial (IA), aprendizado de máquina, processamento de imagens e estatística para capacitar sistemas computacionais a interpretar dados visuais de forma automatizada. Sua aplicação na área da saúde cresceu exponencialmente na última década, impulsionada por avanços em algoritmos de aprendizado profundo e pela disponibilidade de dados médicos digitais, como imagens radiológicas, histológicas e registros de vídeo clínico (Esteva *et al.*, 2021). Esta seção explora os conceitos fundamentais, as tecnologias subjacentes e os principais métodos utilizados em visão computacional aplicada à saúde.



## 2.1 CONCEITOS FUNDAMENTAIS

A visão computacional é uma área da inteligência artificial que capacita computadores a interpretar e analisar dados visuais, como imagens e vídeos, com aplicações amplas e impactantes na área da saúde. Suas funções incluem a segmentação de imagens, classificação de padrões, e reconstrução tridimensional, essenciais para diagnóstico e planejamento clínico. Nos últimos anos, a integração de redes neurais convolucionais (CNNs) trouxe avanços significativos, permitindo que algoritmos superassem métodos tradicionais em diversas tarefas (Esteve *et al.*, 2021).

A primeira etapa no processo de visão computacional é a aquisição de imagens. Exames como raios-X, tomografias computadorizadas (TC) e ressonâncias magnéticas (RM) geram dados visuais que são convertidos em representações digitais. A qualidade da imagem é essencial, pois influenciará diretamente a precisão da análise computacional. Por isso, técnicas de pré-processamento são amplamente aplicadas. Métodos como filtragem de ruído e equalização de histograma aumentam o contraste, melhoram a nitidez e reduzem artefatos, otimizando a análise subsequente (Ahad *et al.*, 2018).

A segmentação de imagens, um dos conceitos mais fundamentais, é amplamente empregada para isolar regiões de interesse, como órgãos ou lesões. Em particular, métodos baseados em aprendizado profundo, como U-Net, são projetados especificamente para aplicações médicas. A evolução das arquiteturas modernas em visão computacional, como descrito por Weiss *et al.* (2020), trouxe novos paradigmas que integram teorias geométricas e modelos de aprendizado profundo, expandindo aplicações em diagnóstico e reconstrução 3D. Essas inovações têm permitido que a visão computacional enfrente desafios previamente intratáveis, como a segmentação de tecidos em imagens de baixa resolução, melhorando significativamente a precisão diagnóstica.

A análise histológica também tem se beneficiado da visão computacional. Redes neurais são capazes de identificar padrões celulares em lâminas histológicas, distinguindo entre tecidos normais e cancerígenos. Além disso,





Choi e Seo (2020) destacam que, com o envelhecimento populacional, a integração de visão computacional no monitoramento de doenças visuais também se tornou uma prioridade emergente. Essa abordagem é particularmente relevante em contextos de acessibilidade, onde tecnologias assistivas permitem um diagnóstico precoce e minimizam as barreiras para populações vulneráveis.

Além da segmentação, a classificação de imagens é essencial para identificar padrões específicos. Um exemplo amplamente utilizado é a classificação de lesões dermatológicas, onde algoritmos treinados com redes neurais profundas alcançam acurácia comparável à de dermatologistas em tarefas como a distinção entre lesões benignas e malignas (Elyan *et al.*, 2022).

Outro conceito emergente é a reconstrução tridimensional (3D), que integra múltiplas imagens bidimensionais para criar modelos volumétricos. Isso é particularmente útil no planejamento cirúrgico, onde os modelos 3D fornecem uma visão detalhada das relações anatômicas, permitindo intervenções mais precisas. Por exemplo, na cirurgia cardíaca, a reconstrução 3D permite uma análise mais precisa de válvulas e estruturas internas, reduzindo o risco de complicações intraoperatórias (Singhal *et al.*, 2019).

Porém, a aplicação de visão computacional em saúde enfrenta desafios consideráveis. A qualidade e a diversidade dos dados são cruciais para o treinamento de modelos robustos, mas a obtenção de bases de dados médicas é frequentemente limitada por questões éticas e regulatórias, como o GDPR na União Europeia e a LGPD no Brasil (Noor *et al.*, 2021). Além disso, o desempenho dos modelos pode variar significativamente entre populações, devido a diferenças genéticas e socioeconômicas, ressaltando a necessidade de bases de dados heterogêneas e globalmente representativas (Altameem & Altameem, 2020).

Por fim, a questão da interpretabilidade é outro desafio. Modelos de aprendizado profundo são frequentemente criticados por seu caráter de “caixa-preta”, dificultando a explicação de como decisões foram tomadas. Métodos de explicabilidade, como mapas de ativação visual, estão sendo desenvolvidos para



aumentar a transparência dos modelos e sua aceitação por profissionais da saúde (Ward *et al.*, 2020).

## 2.2 REDES NEURAIAS CONVOLUCIONAIS (cnns)

CNNs têm revolucionado a análise de imagens médicas, alcançando precisão diagnóstica comparável ou superior à de especialistas humanos e identificando características genéticas associadas a predisposições médicas, possibilitando avanços em medicina personalizada (Esteva *et al.*, 2021).

As camadas convolucionais das CNNs extraem características essenciais das imagens, diferenciando tecidos normais de anômalos em exames médicos, enquanto o pooling reduz a dimensionalidade e melhora a robustez dos modelos (Rahman Ahad *et al.*, 2018).

Arquiteturas como a U-Net têm mostrado alta precisão na segmentação de lesões pulmonares em tomografias, sendo úteis para monitorar a progressão de doenças como a COVID-19 (Schmidt *et al.*, 2023).

Redes profundas como ResNet e DenseNet se destacam na classificação de imagens médicas, alcançando desempenho superior ao de especialistas em tarefas como a triagem de mamografias (Elyan *et al.*, 2022).

As CNNs são eficazes na análise multimodal, integrando dados de diferentes modalidades de imagem, como PET e ressonância magnética, para diagnósticos mais precisos (Singhal *et al.*, 2019).

A implementação de CNNs enfrenta desafios devido à necessidade de grandes conjuntos de dados rotulados e barreiras éticas e regulatórias relacionadas à privacidade e ao compartilhamento de dados médicos (Noor *et al.*, 2021).

Técnicas de aprendizado por transferência e bases de dados diversificadas são essenciais para superar a falta de generalização em modelos treinados em populações específicas ou dispositivos limitados (Ward *et al.*, 2020).





### **2.2.1 Redes Generativas Adversariais (GANS)**

As GANs, introduzidas em 2014, representam um dos avanços mais significativos em aprendizado profundo. Essas redes consistem em dois modelos que competem entre si: um gerador, que cria dados sintéticos, e um discriminador, que avalia a autenticidade desses dados. Essa arquitetura permite que as GANs gerem imagens altamente realistas, uma funcionalidade que tem sido amplamente explorada no setor médico. Por exemplo, as GANs podem ser usadas para aumentar conjuntos de dados médicos ao criar imagens sintéticas que simulam casos reais, reduzindo a dependência de grandes volumes de dados rotulados (Esteva *et al.*, 2021).

Um caso de uso relevante envolve a geração de imagens de tomografia computadorizada ou ressonância magnética de órgãos afetados por doenças raras. Isso permite o treinamento de modelos em cenários onde os dados são escassos, como em pacientes pediátricos ou condições específicas. Em um estudo recente, as GANs foram utilizadas para gerar imagens pulmonares sintéticas de pacientes com COVID-19, auxiliando no treinamento de modelos diagnósticos em estágios iniciais da pandemia, quando os dados reais eram limitados (Ramesh *et al.*, 2022).

Além disso, as GANs têm aplicações no aprimoramento de imagens médicas. Técnicas de super-resolução baseadas em GANs podem melhorar a qualidade de imagens de baixa resolução, como as obtidas em dispositivos portáteis, tornando-as mais úteis para diagnósticos clínicos (Singhal *et al.*, 2019). Esses avanços são particularmente valiosos em regiões com recursos limitados, onde o acesso a equipamentos médicos avançados é restrito.

### **2.2.2 Aprendizado Auto Supervisionado**

O aprendizado auto-supervisionado é uma técnica emergente que permite que modelos aprendam representações úteis sem depender de anotações manuais extensivas. Em vez de rótulos explícitos, os modelos utilizam



Informações implícitas nos próprios dados para criar tarefas auxiliares. Por exemplo, uma tarefa auto-supervisionada pode envolver prever a orientação de uma imagem ou completar partes ausentes, forçando o modelo a aprender características relevantes durante o processo.

No contexto médico, o aprendizado auto-supervisionado está revolucionando a análise de imagens, especialmente em cenários onde a rotulação manual é cara e demorada. Estudos recentes mostram que essa abordagem pode reduzir significativamente os requisitos de dados rotulados, mantendo a precisão diagnóstica em níveis elevados (Esteve *et al.*, 2021). Por exemplo, modelos auto-supervisionados foram aplicados à segmentação de imagens histológicas, onde a falta de anotações consistentes entre patologistas muitas vezes limita o treinamento de modelos supervisionados.

Uma aplicação interessante é o uso do aprendizado auto-supervisionado em imagens multimodais, como a integração de dados de ultrassom e ressonância magnética. Essa abordagem permite que os modelos aprendam a combinar informações de diferentes fontes para melhorar a precisão diagnóstica, mesmo em condições de dados escassos (Schmidt *et al.*, 2023).

### **2.2.3 Explicabilidade da IA**

A explicabilidade, ou "explainable AI" (XAI), é um campo emergente que busca aumentar a transparência dos modelos de aprendizado profundo, tornando suas decisões mais compreensíveis para os usuários finais. Na saúde, a falta de interpretabilidade é uma barreira significativa para a adoção de modelos avançados, já que os profissionais médicos frequentemente hesitam em confiar em sistemas cujas decisões não podem ser justificadas.

Ferramentas de XAI, como mapas de calor e visualizações de atenção, são amplamente utilizadas para indicar quais regiões de uma imagem foram mais influentes para a decisão de um modelo. Por exemplo, em diagnósticos baseados em mamografias, um modelo pode destacar áreas específicas que



indicam a presença de um tumor, fornecendo uma explicação visual que auxilia os radiologistas (Ward *et al.*, 2020).

A explicabilidade também desempenha um papel crucial na detecção de vieses algorítmicos. Modelos treinados em dados não representativos podem apresentar vieses que afetam negativamente populações específicas. A XAI ajuda a identificar esses problemas ao revelar como diferentes características influenciam as decisões do modelo, permitindo ajustes para melhorar a equidade e a precisão (Noor *et al.*, 2021).

#### **2.2.4 Avanços Futuros e Perspectivas**

O desenvolvimento contínuo dessas técnicas emergentes está direcionando a visão computacional para um futuro mais robusto e acessível na saúde. A combinação de GANs, aprendizado auto-supervisionado e XAI está criando modelos mais eficientes, que requerem menos dados rotulados e oferecem maior transparência. Além disso, a integração dessas tecnologias com dispositivos móveis e plataformas baseadas em nuvem está expandindo seu alcance, permitindo aplicações em regiões com recursos limitados.

Com o avanço contínuo, espera-se que essas técnicas desempenhem um papel central na medicina personalizada, fornecendo ferramentas poderosas para diagnósticos mais precisos, tratamentos otimizados e pesquisa clínica.

#### **2.2.5 Aplicações de Visão Computacional na Saúde**

As aplicações de visão computacional na saúde estão redefinindo as práticas médicas e científicas, promovendo maior precisão, eficiência e acessibilidade. Esses avanços abrangem desde diagnósticos automatizados até intervenções cirúrgicas assistidas, impactando positivamente o cuidado ao paciente e a pesquisa biomédica. Nesta seção, serão detalhadas as principais áreas de aplicação, destacando exemplos concretos e evidências científicas que validam o impacto dessas tecnologias.



## 4 RESULTADOS E DISCUSSÕES

### 4.1 DIAGNÓSTICOS AUTOMATIZADOS

A visão computacional tem gerado avanços expressivos no diagnóstico médico automatizado, permitindo que algoritmos, como redes neurais convolucionais (CNNs), alcancem precisão comparável ou superior à de especialistas humanos. Exemplos incluem a detecção de câncer em exames de mamografia, tomografias computadorizadas e ressonâncias magnéticas, com acurácia superior a 90%, reduzindo falsos negativos (Esteva *et al.*, 2021). Em oftalmologia, a tecnologia tem contribuído no diagnóstico precoce de retinopatia diabética, prevenindo casos de cegueira. Durante a pandemia de COVID-19, Cuñttoi (2022) destacou a aplicação de sistemas baseados em IoT e aprendizado profundo para triagens em larga escala, mesmo em ambientes remotos.

O monitoramento remoto, como analisado por Germanese *et al.* (2023), tem sido uma inovação crucial, proporcionando diagnósticos não invasivos, especialmente em pediatria e para crianças com necessidades especiais, otimizando cuidados e reduzindo a carga para os cuidadores. Na análise histológica, redes neurais diferenciam tecidos normais de cancerígenos, acelerando diagnósticos e reduzindo a subjetividade das interpretações manuais (Ahad *et al.*, 2018).

### 4.2 INTERVENÇÕES CIRÚRGICAS ASSISTIDAS

A integração de visão computacional nas salas de cirurgia tem revolucionado a prática cirúrgica, aumentando a segurança e a eficiência. Ferramentas como o da Vinci Surgical System utilizam algoritmos avançados para guiar instrumentos robóticos com alta precisão (Ward *et al.*, 2020). Em cirurgias minimamente invasivas, algoritmos rastreiam tecidos e auxiliam na segmentação em tempo real, aprimorando a visualização de órgãos e vasos, reduzindo riscos de lesões acidentais e o tempo operatório (Singhal *et al.*, 2019).



Além disso, a realidade aumentada proporciona projeções tridimensionais no campo cirúrgico, orientando cirurgiões em procedimentos complexos, como neurocirurgias e intervenções cardíacas, e contribuindo para melhores resultados pós-operatórios (Kennedy-Metz *et al.*, 2021).

#### 4.3 MONITORAMENTO CLÍNICO

A visão computacional tem desempenhado um papel essencial no monitoramento hospitalar em tempo real, especialmente em UTIs. Noor *et al.* (2021) relatam que sistemas equipados com câmeras e algoritmos avançados monitoram sinais vitais e movimentos dos pacientes, permitindo uma gestão clínica mais abrangente. Em enfermarias geriátricas, algoritmos identificam padrões de risco, prevenindo quedas e emitindo alertas para intervenções imediatas (Germanese *et al.*, 2023).

No monitoramento remoto, dispositivos portáteis com câmeras e sensores analisam sinais vitais, beneficiando pacientes com condições crônicas, como insuficiência cardíaca. Essas tecnologias reduzem hospitalizações frequentes e melhoram a qualidade de vida (Altameem & Altameem, 2020).

#### 4.4 INTEGRAÇÃO E EXPLICABILIDADE

A pandemia de COVID-19 acelerou o uso de visão computacional na telemedicina. Algoritmos analisam imagens enviadas por pacientes, como lesões cutâneas ou sintomas respiratórios, ajudando na triagem e priorização de casos, especialmente em áreas remotas com acesso limitado a especialistas (Esteve *et al.*, 2021).

A triagem automatizada também tem sido aplicada em emergências hospitalares. Câmeras monitoram pacientes para identificar sinais visíveis de sofrimento, como dificuldades respiratórias, otimizando o atendimento em situações críticas (Ward *et al.*, 2020).



A revisão destaca a quadro 1 abaixo como um norteador para futuras buscas científicas, aja vista que a interdisciplinaridade ainda é uma barreira a ser conquistada.

Quadro 1. Análise dos Artigos

Tópico	Ideias Principais	Autores
<b>Lacunas Educacionais em Saúde e Tecnologia</b>	- Profissionais de saúde carecem de formação técnica em aprendizado profundo e visão computacional.	Singhal <i>et al.</i> (2019)
	- Cientistas da computação desconhecem as necessidades práticas dos ambientes clínicos.	Singhal <i>et al.</i> (2019)
	- Apenas 20% dos cursos médicos abordam inteligência artificial, com foco insuficiente em aplicações práticas no diagnóstico clínico.	Noor <i>et al.</i> (2021)
<b>Acessibilidade de Dados e Ferramentas Educacionais</b>	- Regulamentações como GDPR e LGPD limitam o acesso a dados médicos, dificultando o treinamento de modelos.	Esteva <i>et al.</i> (2021)
	- Rotulação de imagens médicas é cara e demorada, exigindo especialistas.	Esteva <i>et al.</i> (2021)
	- Iniciativas como CheXpert e ISIC Archive ainda não cobrem a diversidade necessária para casos clínicos globais.	Ward <i>et al.</i> (2020)
<b>Complexidade Técnica e Barreiras de Adoção</b>	- Redes neurais profundas operam como "caixas-pretas", dificultando a compreensão dos resultados pelos profissionais de saúde.	Kennedy-Metz <i>et al.</i> (2021)
	- A falta de explicabilidade nos algoritmos cria desafios éticos e legais na aceitação clínica.	Kennedy-Metz <i>et al.</i> (2021)
	- A heterogeneidade de dispositivos e métodos de aquisição de imagens prejudica a implementação uniforme e a generalização dos modelos.	Altameem & Altameem (2020)

Fonte: Elaborado pelos autores.

Para abordar as lacunas educacionais, a proposta segundo Elyan *et al.*, (2022) são fundamentar e promover iniciativas interdisciplinares que combinem ensino de ciência da computação e aplicações clínicas como observamos no quadro 2 abaixo:





Quadro 2. Resultados

Proposta	Descrição
<b>Currículos Multidisciplinares</b>	Incorporar disciplinas de inteligência artificial e visão computacional em cursos de graduação e pós-graduação em medicina, com foco em aplicações práticas. Em cursos de ciência da computação, incluir módulos sobre desafios médicos e éticos associados à saúde.
<b>Plataformas de Aprendizado Interativo</b>	Desenvolver plataformas educacionais baseadas em casos clínicos reais, permitindo que estudantes experimentem algoritmos de visão computacional com dados simulados ou anonimizados, incluindo simulações de diagnósticos automatizados e segmentação de imagens médicas.
<b>Workshops e Treinamentos Práticos</b>	Promover workshops interdisciplinares reunindo médicos, engenheiros biomédicos e cientistas da computação para colaborar no desenvolvimento de soluções em visão computacional, favorecendo uma compreensão prática dos desafios e oportunidades.
<b>Melhoria no Acesso a Dados</b>	Estimular colaborações internacionais para criar bancos de dados diversificados e anonimizados para fins educacionais. Explorar técnicas como aprendizado federado para treinar modelos sem compartilhamento direto de dados.

Fonte: Elaborado pelos autores.

Por fim, a educação contínua para profissionais da saúde é essencial para garantir que a adoção de visão computacional seja sustentável. A criação de programas de especialização em inteligência artificial aplicada à saúde pode preparar os profissionais para lidar com essas tecnologias de maneira eficaz. Além disso, a formação de equipes multidisciplinares, compostas por cientistas da computação, médicos e engenheiros, será essencial para integrar com sucesso a visão computacional na prática clínica (Schmidt *et al.*, 2023).

O futuro da visão computacional na saúde é promissor, à medida que tecnologias emergentes, integração multidisciplinar e avanços em regulamentações éticas estão convergindo para redefinir os padrões de atendimento médico. Contudo, os desafios relacionados à explicabilidade, acessibilidade de dados e capacitação profissional continuarão a exigir atenção concentrada da comunidade acadêmica, do setor industrial e das instituições governamentais.

Nos próximos anos, espera-se que os sistemas de visão computacional se tornem ainda mais sofisticados, impulsionados por avanços em aprendizado profundo e computação em nuvem. Modelos baseados em aprendizado auto-supervisionado e por transferência estão em evolução constante, permitindo que



sistemas clínicos aproveitem conjuntos de dados limitados ou parcialmente anotados. Um exemplo disso é a integração de redes generativas adversariais (GANs) para aumentar artificialmente conjuntos de dados médicos com imagens sintéticas, melhorando a robustez e a generalização dos algoritmos (Esteve *et al.*, 2021).

Na perspectiva de Zvaríková (2022) destaca a fusão de dados multimodais como uma área promissora, integrando sensores vestíveis e imagens médicas para diagnósticos rápidos e personalizados, melhorando o monitoramento remoto. Contudo, Nazir *et al.* (2020) enfatizam a importância de sistemas de IA explicável (XAI) para aumentar a confiança em decisões clínicas assistidas por algoritmos. Reforçar a necessidade de transparência algorítmica em ambientes críticos, como salas de cirurgia, para garantir segurança e aceitação (Kennedy-Metz *et al.*, 2021).

Porém, Altameem & Altameem (2020) defendem a colaboração interdisciplinar como chave para superar barreiras na visão computacional aplicada à saúde apontando juntamente com Noor *et al.* (2021) o aprendizado federado como uma solução para preservar a privacidade dos dados enquanto melhora a precisão em diagnósticos.

A inclusão de inteligência artificial nos currículos médicos para capacitar profissionais no uso de tecnologias avançadas sublinham a eficácia interdisciplinar (Marques e Ferreira, 2020)

Para Parvaiz *et al.* (2022) destacam que transformers em visão médica oferecem alta generalização, mas exigem formação técnica e infraestrutura avançada. A educação continuada deve equilibrar especialização técnica e ética, como enfatizado por Kennedy-Metz *et al.* (2021), para uma implementação sustentável de IA em saúde.

Noor *et al.* (2021) ressaltam que regulamentações como LGPD e GDPR fortalecem a confiança em IA ao priorizar privacidade e transparência, enquanto Ward *et al.* (2020) reforçam a importância de decisões auditáveis para evitar erros com consequências graves.



## **5 CONCLUSÃO**

Este artigo sintetizou avanços e desafios da visão computacional aplicada à saúde. Foram identificadas barreiras significativas relacionadas à replicabilidade dos modelos e à heterogeneidade das bases de dados, que limitam a adoção ampla dessas tecnologias.

Para superar essas limitações, propõe-se o fortalecimento da colaboração interdisciplinar entre médicos, cientistas de dados e engenheiros, além do desenvolvimento de currículos educacionais que integrem competências em inteligência artificial e saúde.

Por fim, este estudo reafirma a importância da ética e da transparência algorítmica no desenvolvimento de soluções em saúde digital combinando avanços tecnológicos com iniciativas educacionais e regulatórias, a visão computacional.

## **AGRADECIMENTOS**

O presente trabalho foi realizado com apoio da coordenação de aperfeiçoamento de pessoal de nível superior – Brasil (CAPES) – Código de Financiamento 001.



## REFERÊNCIAS

AHAD, M. A. R.; KOBASHI, S.; TAVARES, J. Advancements of image processing and vision in healthcare. **Journal of Healthcare Engineering**, v. 2018, 2018.

ALTAMEEM, T.; ALTAMEEM, A. Facial expression recognition using human-machine interaction in healthcare. **Image Vision Computing**, v. 103, p. 104044, 2020.

CHEN, Y. Computer vision in medical imaging: applications and research challenges. **Journal of Medical Imaging**, v. 1, n. 1, p. 123-136, 2013.

CHOI, S.; SEO, J. Trends in healthcare research on visual impairment and blindness: Use of bibliometrics and hierarchical cluster analysis. **Ophthalmic Epidemiology**, v. 28, n. 4, p. 277–284, 2020.

CUȚITOI, A.-C. Remote patient monitoring systems, wearable IoT sensor devices, and deep learning-based computer vision algorithms in COVID-19 screening, detection, diagnosis, and treatment. **American Journal of Medical Research**, v. 9, n. 1, 2022.

ELYAN, E.; BELL, D.; AYYAZ, H. Advances in computer vision and machine learning for medical image analysis. **Machine Vision Applications**, v. 33, n. 6, p. 1-23, 2022.

ESTEVA, A.; ROBICQUET, A.; RAMOS, D.; SUAREZ, D. Deep learning-enabled medical computer vision: advances, challenges, and opportunities. **NPJ Digital Medicine**, v. 4, p. 1-12, 2021.

GERMANESE, D. *et al.* Computer vision tasks for ambient intelligence in children's health. *Information*, v. 14, n. 10, 2023.

KENNEDY-METZ, L.; STORCH, B. T.; HAIRE, S. Computer vision in the operating room: opportunities and caveats. **Artificial Intelligence in Surgery**, v. 45, n. 5, p. 23-34, 2021.

MARQUES, I. C. P.; FERREIRA, J. Digital transformation in the area of health: Systematic review of 45 years of evolution. *Health and Technology*, v. 10, n. 3, p. 575–586, 2020.

NAZIR, S.; BHATTI, M.; TAN, S. A comprehensive analysis of healthcare big data management, analytics, and scientific programming. **IEEE Access**, v. 8, p. 95714–95733, 2020.



NOOR, A. *et al.* Challenges ahead for healthcare applications of computer vision and sensors. **Journal of Vision and Health**, v. 12, n. 4, p. 112-124, 2021.

PARVAIZ, A.; ABBASI, K. M.; KHAN, M. Vision transformers in medical computer vision: A contemplative retrospection. **Medical Vision Analysis**, v. 9, p. 13–29, 2022.

RAMESH, D.; TAN, S. L.; MEIER, A. Dissecting self-supervised learning methods for surgical data analysis. **Computer Vision for Surgery**, v. 33, n. 1, p. 45-59, 2022.

SCHMIDT, R.; VIEIRA, T.; DA COSTA, M. Tracking and mapping in medical computer vision: a comprehensive review. **Computer Vision Applications in Healthcare**, v. 45, n. 3, p. 78-99, 2023.

SINGHAL, P.; JAIN, R.; KUMAR, A. Smart technologies for building healthcare models using computer vision. **Journal of Biomedical Vision Systems**, v. 21, n. 7, p. 56-72, 2019.

WARD, A.; CHEN, Y.; JIA, Z.; TAN, K. Explainability in computer vision applied to surgery: bridging the gap between AI and clinical practice. **Artificial Intelligence in Medicine**, v. 58, n. 9, p. 89-104, 2020.

ZVARÍKOVÁ, K. Machine and deep learning algorithms, computer vision technologies, and IoT-based healthcare monitoring systems in COVID-19 prevention, testing, detection, and treatment. **American Journal of Medical Research**, v. 9, n. 1, 2022.